



فرم پیشنهاد پروژه پایانی، دوره‌ی کارشناسی

عنوان پروژه (فارسی): سامانه‌ی پرسش محور مبتنی بر RAG برای توضیح کدهای پایتون

عنوان پروژه (انگلیسی): A Question-Driven RAG-Based System for Explaining Python Code

	نام دانشجو	شماره دانشجویی	بسته اصلی و فرعی	تعداد واحد گذرانده شده	امضا
1	فاطمه صیادزاده	4013613052	نرم افزار(اصلی) و هوش مصنوعی(فرعی)	126	
2					

استاد راهنمای پروژه: دکتر محمدرضا شعیباف

نظر استاد راهنما:

امضای استاد راهنما - تاریخ

مطرح گردید و

در شورای گروه

این پیشنهاد در تاریخ

☐ بدون تغییر مورد تصویب قرار گرفت.☐ با شرایط زیر مورد تصویب قرار گرفت.☐ به دلایل زیر مورد تصویب قرار نگرفت.

تاریخ و امضا:

عضو هیئت علمی بررسی کننده:

۱. موضوع پروژه و اهداف آن را به اختصار شرح دهید.

امروزه بسیاری از پروژه‌های نرم‌افزاری، به‌خصوص پروژه‌هایی که در طول زمان توسعه یافته‌اند یا مستندات کافی ندارند، برای توسعه‌دهندگان به یک «جعبه سیاه» تبدیل می‌شوند. در چنین پروژه‌هایی، پیدا کردن محل پیاده‌سازی یک منطق خاص، فهم ارتباط بین بخش‌های مختلف کد و تشخیص نقش هر قسمت از برنامه زمان زیادی از توسعه‌دهنده می‌گیرد. این مسئله به‌ویژه هنگام ورود نیروی جدید به تیم، نگهداشت کدهای قدیمی، رفع خطا یا توسعه قابلیت‌های جدید، باعث افزایش هزینه و کاهش سرعت توسعه می‌شود.

ابزارهای رایج جستجوی کد معمولاً بر پایه جستجوی متنی و کلمات کلیدی عمل می‌کنند. در نتیجه اگر توسعه‌دهنده دقیقاً نداند در کد از چه نامی استفاده شده است، ممکن است نتواند بخش مرتبط را پیدا کند. برای مثال، ممکن است کاربر بپرسد «کجا توکن کاربر ساخته می‌شود؟»، اما در کد از نام‌هایی مانند `generate_token`، `create_access_token` یا `issue_jwt` استفاده شده باشد. در چنین حالتی، جستجوی ساده متنی کافی نیست و نیاز به جستجوی معنایی و درک بهتر ساختار کد وجود دارد. پژوهش‌هایی مانند `CodeSearchNet` نیز اهمیت بازیابی کد مرتبط بر اساس پرسش زبان طبیعی را نشان داده‌اند.[1]

هدف این پروژه، طراحی و پیاده‌سازی یک سامانه پرسش‌محور مبتنی بر RAG برای توضیح کدهای پایتون است. در نسخه اولیه و برای کنترل محدوده پروژه، تمرکز سامانه بر پروژه‌های پایتون کوچک و متوسط خواهد بود. در این سامانه، کاربر با طرح یک پرسش طبیعی درباره منطق پروژه، سامانه را برای یافتن بخش‌های مرتبط کد هدایت می‌کند. سپس سامانه تلاش می‌کند بخش‌های محتمل و مرتبط کد را شناسایی کرده و برای همان بخش‌ها توضیح یا مستند اولیه هدفمند تولید کند.

برای نمونه، اگر کاربر بپرسد: «کجا توکن کاربر بعد از ورود ساخته می‌شود؟»، خروجی مورد انتظار سامانه شامل چند بخش خواهد بود: ابتدا بخش‌های مرتبط کد مانند تابع مربوط به ورود کاربر و تابع مربوط به تولید توکن بازیابی می‌شوند؛ سپس نقش هر بخش به‌صورت خلاصه توضیح داده می‌شود؛ و در نهایت یک مستند اولیه هدفمند شامل هدف بخش، ورودی‌ها، خروجی‌ها و فایل‌ها یا توابع مرتبط ارائه می‌گردد. بنابراین، هدف پروژه مستندسازی کامل و خودکار کل پایگاه کد نیست، بلکه تولید توضیح و مستند اولیه برای بخش‌هایی است که با پرسش کاربر مرتبط هستند.

یکی از قابلیت‌های مورد بررسی در این پروژه، امکان طرح پرسش به زبان طبیعی، از جمله زبان فارسی، در محدوده پروژه‌های آزمایشی است. برای مثال پرسش‌هایی مانند «کجا احراز هویت کاربر انجام می‌شود؟» یا «کدام بخش مسئول تولید توکن است؟» می‌توانند به‌عنوان ورودی سامانه در نظر گرفته شوند. سامانه تلاش می‌کند بر اساس محتوای واقعی پروژه، بخش‌های مرتبط را شناسایی کرده و توضیح یا مستندی قابل استفاده برای توسعه‌دهنده تولید کند. در صورت امکان، خروجی تولیدشده همراه با ارجاع به محل‌های مرتبط در کد نمایش داده می‌شود تا کاربر بتواند صحت آن را بررسی کند.

این پروژه از یک سو به توسعه‌دهندگان کمک می‌کند تا سریع‌تر نقش بخش‌های مختلف کد را درک کنند، و از سوی دیگر می‌تواند به کاهش زمان ورود نیروهای جدید به پروژه و بهبود نگهداشت‌پذیری نرم‌افزار کمک کند. همچنین یکی از ملاحظات طراحی سامانه، بررسی امکان کاهش وابستگی به سرویس‌های ابری و استفاده از روش‌هایی است که در صورت فراهم بودن امکانات، بتوانند بخشی از پردازش را در محیط محلی یا کنترل‌شده انجام دهند. با این حال، اجرای کامل محلی به‌عنوان تعهد قطعی پروژه در نظر گرفته نمی‌شود و بسته به امکانات سخت‌افزاری و محدودیت‌های اجرایی بررسی خواهد شد.

۲. روش انجام پروژه را توضیح دهید.

این پروژه به‌صورت مرحله‌ای و با رویکرد تکرارشونده انجام خواهد شد. در مرحله نخست، مسئله درک و نگهداشت کدهای قدیمی و کم‌مستند بررسی شده و کارهای مرتبط در حوزه‌هایی مانند جستجوی معنایی کد، مستندسازی خودکار کد، پاسخ‌گویی به پرسش‌های مربوط به پایگاه کد و استفاده از مدل‌های زبانی در

تحلیل کد مورد مطالعه قرار می‌گیرد. همچنین ابزارها و روش‌های قابل استفاده برای تحلیل کد، بازیابی اطلاعات مرتبط و تولید توضیح مبتنی بر کد بررسی می‌شوند تا محدوده پروژه متناسب با زمان و امکانات موجود تعیین گردد. در مرحله بعد، معماری کلی سامانه طراحی می‌شود. نسخه اولیه سامانه بر پروژه‌های پایتون کوچک و متوسط تمرکز خواهد داشت. سامانه ابتدا فایل‌های پروژه را بررسی کرده و با استفاده از ابزارها و روش‌های تحلیل ساختار کد، بخش‌های مهمی مانند کلاس‌ها، توابع و متدها را شناسایی می‌کند [6]، [7]. سپس این بخش‌ها به واحدهای قابل پردازش تبدیل می‌شوند تا بتوان بر اساس آن‌ها بازیابی اطلاعات مرتبط و تولید توضیح یا مستند اولیه انجام داد.

در ادامه، بخش بازیابی معنایی پیاده‌سازی می‌شود. در این بخش، سامانه برای بخش‌های استخراج‌شده از کد، نمایش مناسبی ایجاد کرده و آن‌ها را در یک ساختار قابل جستجو نگهداری می‌کند. هنگام دریافت پرسش کاربر، سامانه تلاش می‌کند بخش‌های مرتبط با پرسش را بازیابی کند و آن‌ها را برای تولید خروجی مورد استفاده قرار دهد. استفاده از ایده RAG در این بخش باعث می‌شود خروجی نهایی بیشتر بر محتوای واقعی پایگاه کد متکی باشد. [5]

در مرحله بعد، بخش تولید توضیح یا مستند اولیه هدفمند پیاده‌سازی می‌شود. در این بخش، سامانه با استفاده از بخش‌های بازیابی‌شده از کد، توضیحی متناسب با پرسش کاربر تولید می‌کند. هدف این است که خروجی تا حد امکان مبتنی بر محتوای واقعی پروژه باشد و از تولید توضیحات حدسی یا نامرتبب جلوگیری شود. همچنین امکان طرح پرسش با زبان طبیعی، از جمله پرسش‌های فارسی در محدوده پروژه‌های آزمایشی، بررسی و پیاده‌سازی خواهد شد.

برای استفاده از سامانه، یک رابط کاربری ساده طراحی می‌شود تا کاربر بتواند پروژه را معرفی کند، پرسش خود را مطرح نماید، بخش‌های مرتبط بازیابی‌شده را مشاهده کند و توضیح یا مستند اولیه تولیدشده را بررسی نماید.

در پایان، سامانه ارزیابی خواهد شد. برای این منظور، یک یا چند پروژه پایتونی کوچک یا متوسط انتخاب شده و یک مجموعه کوچک از پرسش‌های فارسی درباره منطق آن‌ها تهیه می‌شود. برای هر پرسش، فایل‌ها یا توابع مرتبط به‌عنوان پاسخ مرجع مشخص می‌شوند. سپس بررسی می‌شود که آیا سامانه توانسته است بخش‌های مرتبط را در نتایج بازیابی‌شده پیدا کند یا خیر. همچنین کیفیت توضیح یا مستند اولیه تولیدشده از نظر سازگاری با کد، قابل فهم بودن و مفید بودن برای توسعه‌دهنده بررسی خواهد شد. در صورت امکان، نتایج سامانه با روش‌های ساده‌تر مانند جستجوی کلمه کلیدی مقایسه می‌شود.

۳. آیا این پروژه و یا مشابه آن قبلاً انجام شده است؟ اگر بله، تفاوت‌های این پروژه با پروژه‌های قبلی را ذکر کنید.

بله. در سال‌های اخیر پژوهش‌ها و ابزارهای مختلفی در حوزه‌های مرتبط با جستجوی معنایی کد، نمایش مشترک زبان طبیعی و زبان برنامه‌نویسی، خلاصه‌سازی کد و استفاده از RAG برای بازیابی اطلاعات مرتبط انجام شده است.

پروژه CodeSearchNet یکی از کارهای پایه در حوزه جستجوی معنایی کد است. این کار مجموعه داده و چالشی برای بازیابی قطعات کد بر اساس پرسش زبان طبیعی ارائه کرده و نشان داده است که ارتباط میان توصیف‌های متنی و کد می‌تواند برای یافتن بخش‌های مرتبط برنامه مورد استفاده قرار گیرد [1]. با این حال، تمرکز CodeSearchNet بیشتر بر ارزیابی و بازیابی کد است و به‌صورت مستقیم یک سامانه پرسش‌محور برای تولید توضیح یا مستند اولیه درباره پایگاه کد ارائه نمی‌کند. مدل CodeBERT یکی از مدل‌های شناخته‌شده برای یادگیری نمایش مشترک بین زبان طبیعی و زبان برنامه‌نویسی است. این مدل برای وظایفی مانند جستجوی کد و تولید مستندات کد مورد استفاده قرار گرفته است [2]. تفاوت پروژه حاضر با این کار در آن است که هدف پروژه آموزش مدل جدید نیست، بلکه استفاده از مدل‌ها و روش‌های موجود در قالب یک سامانه کاربردی برای بازیابی بخش‌های مرتبط کد و تولید توضیح هدفمند است.

مدل GraphCodeBERT علاوه بر توکن‌های برنامه از اطلاعات ساختاری مانند جریان داده استفاده می‌کند و نشان می‌دهد که درک ساختار کد برای تحلیل بهتر برنامه اهمیت دارد [3]. پروژه حاضر نیز از این ایده کلی بهره می‌گیرد، اما تمرکز آن بر

ساخت یک نمونه کاربردی برای پروژه‌های پایتون است که بتواند بر اساس پرسش کاربر بخش‌های مرتبط کد را شناسایی و توضیح دهد.

پژوهش ProConSuL نشان می‌دهد که برای تولید توضیحات بهتر درباره کد، استفاده از زمینه پروژه می‌تواند کیفیت مستندسازی را بهبود دهد [4]. پروژه حاضر نیز تلاش می‌کند توضیح یا مستند اولیه را بر اساس بخش‌های مرتبط بازیابی شده از پایگاه کد تولید کند، اما هدف آن مستندسازی کامل و خودکار کل کدبیس نیست، بلکه تولید مستند یا توضیح هدفمند برای بخش‌های مرتبط با پرسش کاربر است.

روش Retrieval-Augmented Generation یا RAG نیز برای ترکیب بازیابی اطلاعات و تولید پاسخ معرفی شده است [5]. در این پروژه از این ایده برای بازیابی بخش‌های مرتبط پایگاه کد پایتون و تولید توضیح یا مستند اولیه مبتنی بر همان بخش‌ها استفاده می‌شود.

در مجموع، تفاوت اصلی این پروژه با کارهای پیشین در ترکیب بازیابی بخش‌های مرتبط کد با تولید توضیح یا مستند اولیه هدفمند برای پرسش کاربر است. برخلاف بسیاری از کارهای یادشده که بیشتر بر مدل‌سازی، ارزیابی، جستجوی کد یا تولید مستندات کلی تمرکز دارند، پروژه حاضر هدف خود را بر ساخت یک نمونه کاربردی و پرسش‌محور برای کمک به فهم کدهای پایتون قرار می‌دهد.

۴. طرح تجاری خود در رابطه با تجاری‌سازی و به‌سودرسانی پروژه انجام‌شده را توضیح دهید.

این پروژه در مرحله نخست جنبه پژوهشی و کاربردی دارد، اما قابلیت تبدیل شدن به یک ابزار کمک‌توسعه‌دهنده برای تیم‌های نرم‌افزاری را نیز دارد. بسیاری از شرکت‌ها دارای پروژه‌هایی هستند که مستندات کافی ندارند و فهم آن‌ها برای نیروهای جدید زمان‌بر است. سامانه پیشنهادی می‌تواند به توسعه‌دهندگان کمک کند با طرح پرسش درباره منطق پروژه، سریع‌تر فایل‌ها و بخش‌های مرتبط کد را پیدا کرده و توضیح قابل فهمی درباره آن‌ها دریافت کنند.

از نظر تجاری، این سامانه می‌تواند در قالب ابزار داخلی سازمانی، نرم‌افزار دسکتاپ، افزونه IDE یا نسخه قابل نصب روی سرور داخلی شرکت‌ها ارائه شود. مدل‌های درآمدی احتمالی شامل فروش نسخه سازمانی، نصب و راه‌اندازی، سفارشی‌سازی برای شرکت‌ها، افزودن پشتیبانی از زبان‌های برنامه‌نویسی دیگر و ارائه پشتیبانی فنی است.

۵. امکانات موردنیاز جهت انجام پروژه را ذکر نمایید.

برای انجام این پروژه به یک لپ‌تاپ یا کامپیوتر شخصی برای توسعه نرم‌افزار، حافظه و فضای ذخیره‌سازی کافی، زبان برنامه‌نویسی Python، ابزارهای مدیریت نسخه مانند Git، کتابخانه‌ها و ابزارهای مناسب برای تحلیل ساختار کد، ابزارهای بازیابی اطلاعات و تولید نمایش معنایی، ابزارهای لازم برای استفاده از مدل‌های زبانی یا تولید توضیح مبتنی بر کد، فریم‌ورک مناسب برای پیاده‌سازی رابط کاربری و چند پروژه پایتونی کوچک یا متوسط برای آزمایش و ارزیابی سامانه نیاز است. در صورت فراهم بودن منابع سخت‌افزاری مناسب، امکان اجرای برخی بخش‌ها به صورت محلی نیز بررسی خواهد شد.

۶. مهم‌ترین منابع و مراجع لازم برای انجام پروژه پیشنهادی را نام ببرید.

- [1] Husain, H., Wu, H.-H., Gazit, T., Allamanis, M., & Brockschmidt, M. (2019). CodeSearchNet Challenge: Evaluating the State of Semantic Code Search. arXiv:1909.09436.
- [2] Feng, Z., et al. (2020). CodeBERT: A Pre-Trained Model for Programming and Natural Languages. Findings of EMNLP.
- [3] Guo, D., et al. (2021). GraphCodeBERT: Pre-training Code Representations with Data Flow. ICLR.

- [4] Lomshakov, V., et al. (2024). ProConSuL: Project Context for Code Summarization with LLMs. EMNLP Industry Track.
- [5] Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.
- [6] Python Software Foundation. Python Documentation.
- [7] Tree-sitter Documentation. Tree-sitter: An Incremental Parsing System for Programming Tools.